Dati, indicatori e analisi empirica in R

Dal dato grezzo alla valutazione di una politica pubblica

Gianluca Monturano, PhD

Ricercatore a tempo determinato (RTDA) in Economia Politica
Dipartimento di Scienze dell'Economia – Università del Salento
gmonturano.github.io

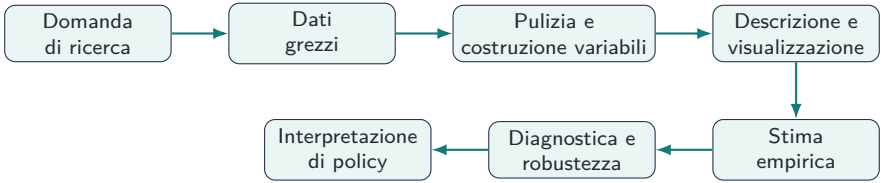
Lezione 11

- **Wickham, H., Çetinkaya-Rundel, M. e Grolemund, G., *R for Data Science***
  Workflow, importazione, trasformazione e visualizzazione dei dati.
- **Wooldridge, J.M., *Introductory Econometrics: A Modern Approach***
  Regressione, dati panel e interpretazione econometrica.
- **Cerulli, G., *Econometric Evaluation of Socio-Economic Programs***
  Valutazione controfattuale e treatment effects.
- **Pacchetti R utilizzati oggi:** `tidyverse`, `fixest`, `sf`.
  Manipolazione dei dati, grafici, regressioni con effetti fissi e dati spaziali.

Obiettivo operativo

Partire da un file grezzo e arrivare a un'analisi empirica riproducibile di una politica pubblica.

Il workflow empirico



- R serve a rendere questo processo **trasparente**, **riproducibile** e **modificabile**.
- Il codice deve raccontare chiaramente come si passa dai dati originali al risultato finale.

Organizzare un progetto R

Una struttura minima evita percorsi assoluti e file sparsi.

```
policy-project/
  data_raw/        # dati originali: non modificare
  data_clean/      # dati prodotti dallo script
  R/
    01_import.R
    02_clean.R
    03_descriptives.R
    04_models.R
  figures/
  tables/
  policy-project.Rproj
```

Regola pratica

Il risultato finale deve poter essere rigenerato eseguendo gli script nello stesso ordine, senza modifiche manuali ai dati.

Caricare pacchetti e dati

Supponiamo di avere un panel impresa–anno con informazioni su investimenti e incentivi.

```
library(tidyverse)
library(fixest)
library(sf)

firms <- read_csv("data_raw/imprese.csv")
policy <- read_csv("data_raw/incentivi.csv")
```

Esempio di variabili:

Variabile	Significato
`id`	identificativo dell'impresa
`year`	anno
`employees`	numero di addetti
`sales`	ricavi
`investment`	investimenti
`rd`	spesa in R&S
`treated`	impresa beneficiaria della politica

Prima regola: guardare i dati

Prima di stimare qualsiasi modello:

```
glimpse(firms)
head(firms)
summary(firms)

firms |>
  count(year)

firms |>
  summarise(
    n_firms = n_distinct(id),
    n_rows  = n(),
    missing_sales = sum(is.na(sales))
  )
```

- Quante unità e quanti anni osserviamo?
- Il panel è bilanciato?
- Dove sono i missing?
- Le unità di misura sono coerenti?

Selezionare, filtrare e rinominare

```
firms_clean <- firms |>
  select(id, year, region, sector,
         employees, sales, investment, rd) |>
  filter(year >= 2018,
         employees > 0,
         sales >= 0) |>
  rename(
    addetti = employees,
    ricavi = sales,
    investimenti = investment
  )
```

Il punto non è usare molte funzioni: è costruire una sequenza leggibile di operazioni.

Pipe

Il simbolo |> si può leggere come “prendi il risultato precedente e poi...”.

Missing, duplicati e controlli di qualità

```
# duplicati impresa-anno
firms_clean |>
  count(id, year) |>
  filter(n > 1)

# quota di missing per variabile
firms_clean |>
  summarise(
    across(
      everything(),
      ~ mean(is.na(.x))
    )
  )
```

- Un missing non è automaticamente un errore.
- Eliminare osservazioni può cambiare la composizione del campione.
- Ogni regola di pulizia deve avere una motivazione economica o informativa.

Costruire indicatori economici

```
firms_clean <- firms_clean |>
  arrange(id, year) |>
  group_by(id) |>
  mutate(
    produttivita = ricavi / addetti,
    inv_per_addetto = investimenti / addetti,
    rd_intensity = rd / ricavi,
    growth_sales = 100 * (log(ricavi) - log(lag(ricavi)))
  ) |>
  ungroup()
```

$$g_{it} = 100\,[\log(Y_{it}) - \log(Y_{i,t-1})]$$

- g_{it}: tasso approssimato di crescita percentuale dell'outcome;
- Y_{it}: valore dell'outcome dell'unità i nell'anno t;
- $Y_{i,t-1}$: valore osservato nell'anno precedente.

Statistiche descrittive per gruppi

```
summary_policy <- data |>
  group_by(treated) |>
  summarise(
    n = n(),
    mean_inv = mean(investimenti, na.rm = TRUE),
    median_inv = median(investimenti, na.rm = TRUE),
    mean_prod = mean(produttivita, na.rm = TRUE),
    sd_prod = sd(produttivita, na.rm = TRUE)
  )
```

	N	Investimenti medi	Produttività media
Controlli	2,840	82.4	191.7
Trattati	1,160	126.8	218.3

La differenza descrittiva è informativa, ma **non è ancora un effetto causale**.

Unire dati amministrativi e dati di policy

Spesso outcome e trattamento provengono da fonti diverse.

```
data <- firms_clean |>
  left_join(
    policy,
    by = c("id", "year")
  ) |>
  mutate(
    treated = replace_na(treated, 0),
    amount  = replace_na(amount, 0)
  )
```

- `left_join()` mantiene tutte le osservazioni del dataset principale.
- La chiave di unione deve identificare correttamente l'unità e il periodo.
- Dopo il join va sempre controllato se il numero di righe è cambiato in modo inatteso.

Da wide a long: preparare il panel

Alcuni file arrivano con un anno per colonna:

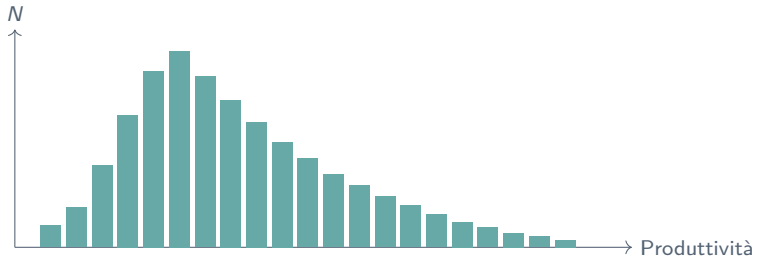
```
wide |>
  pivot_longer(
    cols = starts_with("sales_"),
    names_to = "year",
    values_to = "sales",
    names_prefix = "sales_"
  ) |>
  mutate(year = as.integer(year))
```

Per lavorare con panel e DiD, la struttura tipica è:

id	year	outcome	treated
101	2021	84.2	0
101	2022	87.6	0
101	2023	96.4	1

Visualizzare una distribuzione

```
ggplot(data, aes(x = produttivita)) +
  geom_histogram(bins = 35) +
  labs(
    x = "Produttivita",
    y = "Numero di osservazioni"
  ) +
  theme_minimal()
```

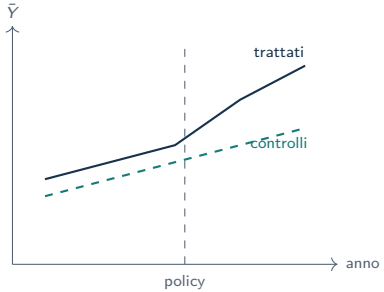


Schema illustrativo: prima di stimare, controllare forma della distribuzione e valori estremi.

Trend di trattati e controlli

```
trend <- data |>
  group_by(year, treated) |>
  summarise(
    y = mean(investimenti, na.rm = TRUE),
    .groups = "drop"
  )

ggplot(trend,
       aes(year, y,
           group = treated,
           linetype = factor(treated))) +
  geom_line(linewidth = 1) +
  geom_point() +
  theme_minimal()
```



Il grafico dei trend è il primo controllo visivo prima di una DiD.

Prima regressione: associazione condizionata

$$Y_i = \alpha + \beta D_i + \gamma' X_i + \varepsilon_i$$

```
m1 <- lm(
  investimenti ~ treated + log(addetti) + factor(sector),
  data = data
)

summary(m1)
```

- Y_i: outcome dell'unità i;
- D_i: indicatore di trattamento;
- X_i: caratteristiche osservabili di controllo;
- β: differenza condizionata associata al trattamento;
- ε_i: componente non osservata.

Regressioni con `fixest`

```
m2 <- feols(
  investimenti ~ treated + log(addetti) + i(sector),
  data = data,
  vcov = "hetero"
)

etable(m2)
```

Per dati raggruppati o panel, gli errori standard possono essere clusterizzati:

```
m2_cluster <- feols(
  investimenti ~ treated + log(addetti),
  data = data,
  cluster = ~ id
)
```

Attenzione

Cambiare gli errori standard non risolve un problema di identificazione: modifica l'inferenza, non il disegno causale.

Effetti fissi nel panel

$$Y_{it} = \alpha_i + \lambda_t + \beta X_{it} + \varepsilon_{it}$$

```
fe_model <- feols(
  investimenti ~ log(addetti) + rd_intensity |
    id + year,
  data = data,
  cluster = ~ id
)
```

- Y_{it}: outcome dell'unità i nel periodo t;
- α_i: effetto fisso dell'unità, costante nel tempo;
- λ_t: effetto fisso temporale comune a tutte le unità;
- X_{it}: regressori che variano nel tempo;
- β: coefficiente associato a X_{it}.

Preparare una difference-in-differences

Supponiamo che la politica inizi nel 2023 per il gruppo trattato.

```
data <- data |>
  mutate(
    post = as.integer(year >= 2023),
    did  = treated * post
  )
```

$$Y_{it} = \alpha_i + \lambda_t + \beta(D_i \times Post_t) + \varepsilon_{it}$$

- D_i: indicatore del gruppo trattato;
- $Post_t$: indicatore del periodo successivo alla policy;
- $D_i \times Post_t$: esposizione effettiva al trattamento;
- β: effetto DiD sotto l'ipotesi di trend paralleli.

Stimare la DiD con effetti fissi

```
did_model <- feols(
  investimenti ~ treated:post |
    id + year,
  data = data,
  cluster = ~ id
)

etable(did_model)
```

Interpretazione:

- il coefficiente su `treated:post` misura la variazione differenziale dei trattati dopo la policy;
- gli effetti fissi di impresa assorbono differenze permanenti tra unità;
- gli effetti fissi temporali assorbono shock comuni a tutti.

Il codice è breve; la credibilità viene dalle ipotesi e dal disegno.

Event study: dinamica e pre-trend

Se conosciamo l'anno relativo al trattamento:

```
data <- data |>
  mutate(
    event_time = year - treatment_year
  )

es <- feols(
  investimenti ~ i(event_time, treated, ref = -1) |
    id + year,
  data = data,
  cluster = ~ id
)

iplot(es)
```

L'event study aiuta a vedere:

- eventuali differenze prima del trattamento;
- dinamica dell'effetto dopo l'intervento;
- persistenza o attenuazione nel tempo.

Dalla tabella alla mappa con `sf`

Un dataset territoriale può essere unito a geometrie comunali o regionali.

```
comuni <- st_read("data_raw/comuni.gpkg")

map_data <- comuni |>
  left_join(
    policy_municipal,
    by = "codice_comune"
  )

ggplot(map_data) +
  geom_sf(aes(fill = treatment_intensity)) +
  theme_void()
```

- La mappa serve per capire **dove** è concentrato il trattamento.
- Può rivelare cluster territoriali, discontinuità e possibili spillover.
- Non sostituisce la strategia di identificazione.

Costruire una misura semplice di esposizione spaziale

Esempio: distanza dalla zona trattata o presenza di vicini trattati.

```
# distanza minima da un'area trattata
nearest <- st_nearest_feature(
  comuni,
  comuni |> filter(treated == 1)
)

comuni$dist_treated <- st_distance(
  comuni,
  (comuni |> filter(treated == 1))[nearest, ],
  by_element = TRUE
)
```

Questo tipo di variabile può essere usato per:

- costruire buffer;
- escludere controlli troppo vicini;
- studiare decadimento degli spillover con la distanza.

Salvare dati, grafici e risultati

```
write_csv(data, "data_clean/panel_policy.csv")

ggsave(
  "figures/trend_treated_control.png",
  width = 8, height = 5, dpi = 300
)

etable(
  m2_cluster, fe_model, did_model,
  tex = TRUE,
  file = "tables/models.tex"
)
```

Principio

Niente screenshot delle regressioni e niente tabelle ricopiate a mano: gli output devono essere generati dal codice.

Da un risultato statistico a una conclusione di policy

Una buona analisi non termina con il segno di un coefficiente.

Passaggio	Domanda
Magnitudine	Quanto è grande l'effetto in termini economici?
Precisione	Quanto è incerta la stima?
Identificazione	Quale ipotesi rende causale il coefficiente?
Eterogeneità	Per quali imprese o territori cambia l'effetto?
Costo	Il beneficio giustifica la spesa pubblica?
Spillover	Parte dell'effetto ricade su unità non trattate?

output di R $\neq$ conclusione economica automatica

Mini-laboratorio: dati e trend

```
library(tidyverse)
library(fixest)

d <- read_csv("data_raw/policy_panel.csv") |>
  filter(year >= 2018) |>
  mutate(
    post = as.integer(year >= 2023),
    prod = sales / employees
  )

trend <- d |>
  group_by(year, treated) |>
  summarise(
    y = mean(prod, na.rm = TRUE),
    .groups = "drop"
  )

ggplot(trend, aes(year, y,
                  linetype = factor(treated))) +
  geom_line() +
  geom_point()
```

Mini-laboratorio: stima e interpretazione

```
m <- feols(
  prod ~ treated:post | id + year,
  cluster = ~ id,
  data = d
)

etable(m)
```

Prima di leggere $\hat{\beta}$ come effetto causale, chiediamoci:

- il gruppo di controllo è credibile?
- i trend pre-policy sono compatibili con l'ipotesi di parallel trends?
- esistono shock differenziali tra gruppi?
- possono esserci spillover o anticipazione del trattamento?

Il modello si stima in poche righe; l'identificazione richiede ragionamento economico.

Checklist per il working paper

Prima di consegnare un'analisi empirica:

1. la domanda di ricerca è formulata chiaramente;
2. ogni variabile importante è definita;
3. il dataset è controllato per missing, duplicati e unità di misura;
4. le statistiche descrittive precedono le regressioni;
5. almeno un grafico mostra i pattern principali;
6. il modello empirico è coerente con il disegno della policy;
7. gli errori standard sono appropriati alla struttura dei dati;
8. i risultati sono interpretati in termini economici, non solo statistici;
9. limiti, selezione e possibili spillover sono discussi;
10. tutto il risultato è riproducibile a partire dagli script R.

Conclusioni

1. R consente di integrare importazione, pulizia, analisi e visualizzazione in un unico workflow.
2. La costruzione delle variabili è parte dell'analisi economica, non un passaggio puramente tecnico.
3. Le descrittive servono a capire i dati prima della stima.
4. Regressioni, effetti fissi e DiD possono essere implementati con poche righe di codice.
5. La credibilità di una valutazione dipende dal disegno empirico, non dalla complessità del codice.
6. Dati spaziali e panel permettono di collegare l'analisi in R ai temi delle lezioni precedenti.

Messaggio centrale

Il codice deve rendere visibile il ragionamento economico: dati $\rightarrow$ identificazione $\rightarrow$ stima $\rightarrow$ interpretazione di policy.

Lezione successiva

Nella Lezione 12 useremo questo workflow per costruire e discutere **applicazioni empiriche complete**.

- scelta della domanda e della policy;
- costruzione del dataset finale;
- grafici diagnostici;
- specificazione empirica;
- lettura dei risultati;
- casi studio e discussione finale del corso.